Usulan Penelitian Kerja Praktik

RANCANG BANGUN APLIKASI PENOMORAN SERTIFIKAT DAN PIAGAM PENGHARGAAN BERBASIS WEBSITE

(Studi Kasus : Pusdiklat dan Sertifikasi Universitas Teknologi Yogyakarta)

Diajukan oleh:

RAMA PANJI NARARENDRA CAHAYA

5231811033

PROGRAM STUDI SAINS DATA

FAKULTAS SAINS & TEKNOLOGI

UNIVERSITAS TEKNOLOGI YOGYAKARTA

2026

KATA PENGANTARBLM TENGAH

DAFTAR ISI

Contents

1.1 RANCANG BANGUN APLIKASI PENOMORAN SERTIFIKAT DAN PIAGAM PENGHARGAAN .....**Error! Bookmark not defined.**
BAB II KATA PENGANTAR 2
DAFTAR ISI 3
DAFTAR TABEL 5
DAFTAR GAMBAR 6
DAFTAR SINGKATAN 7
DAFTAR ISTILAH 8
BAB I PENDAHULUAN 9
1.1 Latar Belakang 9
2.1 Rumusan Masalah 10
2.2 Batasan Masalah 11
2.3 Tujuan Kerja Praktik 11
2.4 Manfaat Kerja Praktik 11
BAB III BAB II .....**Error! Bookmark not defined.**
3.1 Kajian Hasil Penelitian 14
BAB IV BAB III TINJAUAN UMUM INSTANSI 27
BAB V BAB IV .....**Error! Bookmark not defined.**
BAB VI DAFTAR PUSTAKA 33
BAB VII LAMPIRAN 34

KATA PENGANTAR 41
DAFTAR ISI ..... **Error! Bookmark not defined.**
DAFTAR TABEL ..... **Error! Bookmark not defined.**
DAFTAR GAMBAR ..... **Error! Bookmark not defined.**
BAB I PENDAHULUAN ..... **Error! Bookmark not defined.**
I.1 Latar Belakang 47
I.2 Rumusan Masalah ..... **Error! Bookmark not defined.**
I.3 Batasan Masalah ..... **Error! Bookmark**

not defined.

I.4 Tujuan Penelitian..... **Error! Bookmark not defined.**

BAB II TINJAUAN UMUM TEMPAT KERJA PRAKTIK .. **Error! Bookmark not defined.**

II.1 Profil Tempat Kerja Praktik ..... **Error! Bookmark not defined.**

II.2 Struktur Organisasi..... **Error! Bookmark not defined.**

II.3 *Business Rule* Penomoran Sertifikat..... **Error! Bookmark not defined.**

DAFTAR TABEL

Tabel 4. 1 Jadwal Tahapan Penelitian ..... **Error! Bookmark not defined.**

DAFTAR GAMBAR

Gambar 2. 1 Denah Lokasi Tempat Kerja Praktik..... **Error! Bookmark not defined.**

Gambar 2. 2 Struktur Organisasi Universitas Teknologi Yogyakarta..... **Error! Bookmark not**

defined.

DAFTAR SINGKATAN

(bila ada)

DAFTAR ISTILAH

(bila ada)

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan komunikasi telah membawa dampak signifikan pada berbagai sektor industri, termasuk industri pariwisata dan perhotelan. Dalam era digital saat ini, data menjadi aset krusial bagi manajemen hotel untuk menyusun strategi bisnis yang efektif. Pemanfaatan *Big Data* dan *Machine Learning* dalam industri perhotelan memungkinkan manajemen untuk melakukan prediksi permintaan, optimalisasi harga, dan pengelolaan pendapatan (*Revenue Management*) secara lebih akurat(Andy Hermawan dkk, 2025). Ketepatan dalam memprediksi harga kamar rata-rata (*Average Room Rate*) dan tingkat hunian sangat menentukan keberhasilan sebuah properti dalam memaksimalkan keuntungan dan mempertahankan daya saing di pasar.

Genius Hospitality Management (PT Genius Utama Indonesia) merupakan perusahaan yang bergerak di bidang aktivitas konsultansi manajemen yang mengelola berbagai properti perhotelan. Dalam operasionalnya, Genius Hospitality Management menghadapi tantangan dalam menentukan strategi harga yang optimal untuk setiap tipe kamar di berbagai properti yang dikelola. Kompleksitas ini muncul karena setiap properti memiliki karakteristik unik, dan setiap tipe kamar (*room type*) memiliki pola permintaan yang berbeda-beda. Saat ini, data transaksi pemesanan kamar tersimpan secara digital yang memuat informasi mendetail seperti *property_id* (identitas hotel), *room_id* (identitas tipe kamar), waktu pemesanan, serta harga. Namun, besarnya volume data dan variabilitas pola musiman membuat analisis secara manual menjadi tidak efisien dan rentan terhadap kesalahan (*human error*).

Permasalahan lain yang dihadapi adalah inkonsistensi kualitas data dari berbagai saluran pemesanan (*booking channels*). Berdasarkan pengamatan awal pada data internal perusahaan, ditemukan bahwa banyak saluran pemesanan memiliki data yang tidak lengkap atau kosong, yang dapat menurunkan akurasi model prediksi. Oleh karena itu, penelitian ini akan memfokuskan penggunaan data

yang bersumber dari saluran Booking.com, mengingat saluran ini memiliki konsistensi dan kelengkapan data yang paling baik dibandingkan saluran lainnya. Data ini mencakup riwayat harga dan pemesanan yang dapat dijadikan landasan untuk memproyeksikan tren harga di masa mendatang.

Untuk mengatasi permasalahan tersebut, dibutuhkan sebuah sistem yang mampu mengolah data historis menjadi wawasan prediktif. Pendekatan *Sains Data* melalui teknik *Machine Learning* menawarkan solusi untuk melakukan peramalan (*forecasting*) deret waktu (*time series*) dengan tingkat akurasi yang tinggi. Salah satu algoritma yang terbukti efisien dan akurat dalam menangani data tabular dengan skala besar adalah *Light Gradient Boosting Machine* (LightGBM). LightGBM memiliki keunggulan dalam kecepatan pelatihan dan kemampuannya menangani fitur kategorikal, seperti *property_id* dan *room_id*, yang sangat relevan dengan struktur data yang dimiliki oleh Genius Hospitality Management.

Penelitian kerja praktik ini bertujuan untuk merancang dan membangun model *forecasting* rata-rata harga kamar per tipe kamar menggunakan algoritma LightGBM. Sistem ini diharapkan mampu memprediksi rata-rata harga kamar untuk periode mendatang berdasarkan pola historis dari data Booking.com. Dengan adanya prediksi yang spesifik untuk setiap *property_id* dan *room_id*, pihak manajemen Genius Hospitality Management dapat mengambil keputusan yang lebih tepat terkait strategi penetapan harga dinamis (*dynamic pricing*) dan perencanaan operasional, sehingga dapat meningkatkan efisiensi dan profitabilitas perusahaan.

1.1 Rumusan Masalah

Berdasarkan pemaparan latar belakang masalah yang telah diuraikan, maka rumusan masalah yang akan dikaji dalam kerja praktik ini adalah bagaimana merancang dan membangun model *machine learning* menggunakan algoritma *Light Gradient Boosting Machine* (LightGBM) untuk meramalkan (*forecasting*) rata-rata harga kamar per bulan berdasarkan tipe kamar dan properti pada PT Genius Utama Indonesia?

1.2 Batasan Masalah

Agar pembahasan dalam penelitian kerja praktik ini lebih terarah dan fokus pada tujuan yang ingin dicapai, penulis menetapkan batasan masalah sebagai berikut:

1. Data yang digunakan merupakan data transaksi pemesanan kamar historis milik PT Genius Utama Indonesia (Genius Hospitality Management).
2. Sumber data dibatasi hanya pada saluran pemesanan (*channel*) Booking.com untuk menjaga konsistensi dan kelengkapan kualitas data.
3. Prediksi dilakukan secara spesifik berdasarkan *property_id* (identitas hotel) dan *room_id* (identitas tipe kamar).
4. Variabel target yang akan diprediksi adalah rata-rata harga kamar (*average room rate*) per bulan.
5. Metode algoritma yang diimplementasikan untuk pembangunan model peramalan adalah *Light Gradient Boosting Machine* (LightGBM).

1.3 Tujuan Kerja Praktik

Mengacu pada rumusan masalah yang telah disusun, tujuan dari pelaksanaan kerja praktik ini adalah:

1. Membangun model peramalan (*forecasting*) harga kamar rata-rata bulanan yang mampu memproses fitur kategorikal *property_id* dan *room_id* menggunakan algoritma LightGBM.
2. Menghasilkan prediksi harga kamar yang akurat untuk periode mendatang pada setiap tipe kamar di properti yang dikelola oleh PT Genius Utama Indonesia.
3. Mengukur tingkat akurasi model LightGBM dalam memprediksi data *time series* harga kamar berdasarkan data historis dari saluran Booking.com.

1.4 Manfaat Kerja Praktik

Hasil dari pelaksanaan kerja praktik ini diharapkan dapat memberikan

manfaat, baik secara teoritis maupun praktis, bagi berbagai pihak, yaitu:

1. Bagi Perusahaan (PT Genius Utama Indonesia) Hasil prediksi dari sistem ini dapat digunakan sebagai acuan pendukung keputusan dalam strategi penetapan harga dinamis (*dynamic pricing*) dan manajemen pendapatan (*revenue management*). Dengan mengetahui proyeksi harga rata-rata per tipe kamar di masa mendatang, manajemen dapat menyusun strategi penjualan yang lebih efektif untuk memaksimalkan profitabilitas.
2. Bagi Akademisi dan Penulis Penelitian ini menjadi sarana implementasi ilmu Sains Data, khususnya dalam penerapan algoritma *Machine Learning* untuk kasus data *time series* di industri perhotelan. Selain itu, penelitian ini diharapkan dapat menambah referensi kepustakaan mengenai penggunaan LightGBM dalam peramalan harga pada sektor pariwisata.

1.5 Sistemika Penulisan

Untuk mempermudah pembaca dalam memahami alur dan gambaran umum dari proposal kerja praktik ini, maka materi pembahasan disusun dengan sistematika penulisan sebagai berikut:

BAB I PENDAHULUAN

Bab ini berisi gambaran umum mengenai dasar pelaksanaan penelitian kerja praktik. Pembahasan meliputi latar belakang masalah yang mendasari pentingnya prediksi harga kamar, rumusan masalah terkait perancangan model *forecasting*, batasan masalah untuk menjaga fokus penelitian pada data *Booking.com* dan algoritma *LightGBM*, tujuan yang ingin dicapai, manfaat penelitian bagi perusahaan dan akademisi, serta sistematika penulisan proposal.

BAB II KAJIAN HASIL PENELITIAN DAN LANDASAN TEORI

Bab ini memaparkan tinjauan terhadap penelitian terdahulu yang relevan dengan topik *forecasting* harga dan penerapan *machine learning* pada data *time series*. Selain itu, bab ini juga menjelaskan landasan teori yang menjadi dasar pemecahan masalah, mencakup teori mengenai Sains Data, konsep *forecasting*, analisis *time series*, serta prinsip kerja algoritma *Light Gradient Boosting Machine* (LightGBM) yang digunakan dalam pembangunan model.

BAB III TINJAUAN UMUM INSTANSI

Bab ini membahas mengenai profil instansi tempat pelaksanaan kerja praktik, yaitu PT Genius Utama Indonesia (*Genius Hospitality Management*). Uraian dalam bab ini mencakup gambaran umum perusahaan, struktur organisasi yang berlaku, serta proses bisnis atau aturan bisnis (*business rule*) yang berjalan saat ini, khususnya yang berkaitan dengan pengelolaan data properti, pemesanan kamar, dan strategi penetapan harga.

BAB IV METODE KERJA PRAKTIK

Bab ini menguraikan metodologi dan langkah-langkah teknis yang akan dilakukan dalam penyelesaian masalah. Pembahasan meliputi tahapan kerja praktik mulai dari pemahaman bisnis hingga evaluasi model, deskripsi data transaksi historis yang digunakan (termasuk variabel *property_id*, *room_id*, dan *price*), serta rencana jadwal pelaksanaan kerja praktik yang disusun berdasarkan estimasi waktu setiap tahapan kegiatan.

BAB II
KAJIAN HASIL PENELITIAN DAN LANDASAN TEORI

2.1 Kajian Hasil Penelitian

Penelitian terkait peramalan (*forecasting*) dan prediksi harga menggunakan algoritma *Machine Learning* telah banyak dilakukan dalam beberapa tahun terakhir. Tinjauan terhadap penelitian-penelitian ini penting untuk memetakan posisi penelitian yang diusulkan serta memahami keunggulan metode *Light Gradient Boosting Machine* (LightGBM) dibandingkan metode lainnya, khususnya dalam konteks data *time series* dan industri perhotelan.

Astarani, G.A.R. dkk. (2025) melakukan analisis perbandingan antara algoritma XGBoost dan LightGBM dalam konteks prediksi penjualan ritel menggunakan *dataset* Walmart Store Sales. Penelitian ini menggunakan metodologi yang komprehensif mulai dari *preprocessing*, seleksi fitur, hingga evaluasi model. Hasil penelitian menunjukkan bahwa LightGBM memberikan performa prediksi yang lebih unggul dibandingkan XGBoost dengan nilai *Mean Squared Error* (MSE) sebesar 0,0341 dan *Root Mean Squared Error* (RMSE) sebesar 0,1847. Penelitian ini membuktikan efektivitas LightGBM dalam menangani data penjualan berskala besar yang memiliki karakteristik mirip dengan data pemesanan kamar hotel.

Dalam sektor akomodasi dan hunian sewa, Rahman dkk. (2025)menerapkan algoritma XGBoost dengan pendekatan *Knowledge Discovery in Database* (KDD) untuk memprediksi harga sewa kos di Kota Samarinda. Data diperoleh melalui proses *web scraping* dengan mempertimbangkan fitur fasilitas dan lokasi. Meskipun penelitian ini menggunakan XGBoost dan menghasilkan *Mean Absolute Percentage Error* (MAPE) sebesar 18%, peneliti menekankan pentingnya penggunaan fitur yang relevan dalam meningkatkan akurasi prediksi harga properti. Hal ini relevan dengan penelitian yang diusulkan yang akan menggunakan fitur spesifik seperti *property_id* dan *room_id*.

Pramita dkk. (2026) mengembangkan model prediksi permintaan hotel (*Hotel Demand*) menggunakan metode *Random Forest Regression*. Penelitian ini

menggunakan variabel internal seperti tingkat hunian, reservasi, dan pembatalan, serta variabel eksternal seperti acara dan jumlah pengunjung. Hasil evaluasi menunjukkan bahwa variabel internal memiliki pengaruh signifikan terhadap akurasi peramalan permintaan. Keterkaitan penelitian ini dengan kerja praktik yang diusulkan terletak pada penggunaan data historis internal hotel sebagai basis utama dalam melakukan peramalan untuk mendukung pengambilan keputusan manajemen.

Selanjutnya, Aulady dkk. (2024) meneliti penerapan metode LightGBM yang dioptimalkan dengan *Hyper-Parameter Tuning* menggunakan *GridSearchCV* untuk memprediksi harga mobil bekas. Penelitian ini menyoroti kemampuan LightGBM dalam menangani data regresi dengan kecepatan pelatihan yang tinggi. Hasil penelitian menunjukkan bahwa proses *tuning* parameter secara signifikan meningkatkan performa model, dengan hasil evaluasi MSE sebesar 0,034 dan *R-Square* sebesar 0,89. Temuan ini menjadi landasan penting bagi penulis untuk menerapkan teknik optimalisasi serupa pada model LightGBM dalam memprediksi rata-rata harga kamar.

Di sisi lain, penelitian mengenai peramalan tingkat penghunian kamar (TPK) hotel bintang lima di Bali dilakukan oleh Pujiningrum, R.D. dan Sulistijanti (2024) menggunakan metode statistik klasik ARIMA dan *Fuzzy Time Series* Chen. Hasil penelitian menunjukkan bahwa untuk data dengan pola musiman yang kuat, metode ARIMA (1,1,1) memberikan hasil yang cukup baik dengan MAPE di bawah 10%. Namun, penelitian ini juga menunjukkan keterbatasan metode statistik klasik dalam menangani data yang sangat fluktuatif dibandingkan dengan pendekatan *machine learning* modern.

Terakhir, Herlambang, N.M. dan Azies, H.A. (2026) membandingkan kinerja algoritma ARIMA dan Prophet dalam peramalan harga saham. Hasil analisis menunjukkan bahwa meskipun ARIMA memberikan akurasi numerik yang baik pada data jangka pendek, metode *forecasting* modern diperlukan untuk menangani kompleksitas data *time series* yang lebih dinamis. Hal ini mendukung pemilihan algoritma berbasis *boosting* seperti LightGBM yang direncanakan dalam

kerja praktik ini untuk menangani data harga kamar yang memiliki variabilitas tinggi antar tipe kamar dan properti.

Berdasarkan kajian terhadap penelitian-penelitian di atas, terlihat bahwa penggunaan algoritma *Gradient Boosting* khususnya LightGBM memiliki performa yang sangat baik untuk kasus regresi dan peramalan pada dataset yang besar. Namun, belum banyak penelitian yang secara spesifik menerapkan LightGBM untuk memprediksi rata-rata harga kamar (*Average Room Rate*) secara spesifik per tipe kamar (*room_id*) dan properti (*property_id*) menggunakan data dari saluran *Booking.com*. Oleh karena itu, penelitian ini bertujuan untuk mengisi celah tersebut dengan membangun model peramalan harga yang spesifik dan akurat untuk PT Genius Utama Indonesia.

2.2 Landasan Teori

2.2.1 Manajemen Pendapatan Hotel

Manajemen Pendapatan atau *Revenue Management* dalam industri perhotelan didefinisikan sebagai seni dan ilmu dalam memprediksi permintaan konsumen secara *real-time* serta mengoptimalkan harga dan ketersediaan produk untuk menyesuaikan dengan permintaan tersebut. Tujuannya adalah menjual kamar yang tepat, kepada pelanggan yang tepat, pada waktu yang tepat, dengan harga yang optimal untuk memaksimalkan pendapatan finansial (Lima Santos dkk, 2024). Dalam praktiknya, strategi ini sangat bergantung pada konsep penetapan harga dinamis (*dynamic pricing*), di mana harga kamar berfluktuasi berdasarkan faktor-faktor seperti tingkat hunian saat ini (*occupancy*), pola pemesanan, serta faktor musiman (*seasonality*) yang mencakup periode *Low Season*, *High Season*, hingga *Peak Season*.

Salah satu indikator kinerja utama (*Key Performance Indicator*) yang digunakan untuk mengevaluasi efektivitas strategi harga tersebut adalah *Average Room Rate* (ARR) atau sering juga disebut *Average Daily Rate* (ADR). ARR merepresentasikan rata-rata harga sewa kamar yang terjual dalam periode waktu tertentu dan menjadi variabel target utama yang akan diprediksi dalam penelitian ini. Nilai ARR dihitung dengan cara membagi total pendapatan kamar dengan

jumlah total kamar yang terjual, sebagaimana dinyatakan dalam Persamaan 2.1 (Budi Darma & Wirawati, 2019).

$$ARR = \frac{\text{Total Pendapatan Kamar}}{\text{Total Kamar Terjual}} \tag{2.1}$$

2.2.2 Time Series Forecasting

Time Series atau deret waktu didefinisikan sebagai urutan kronologis pengamatan pada suatu variabel yang menjadi perhatian, yang dikumpulkan pada interval waktu yang berurutan (Montgomery dan Jennings, 2024). Dalam konteks peramalan (*forecasting*), proses ini dimaknai sebagai upaya penentuan nilai masa depan berdasarkan nilai-nilai sebelumnya yang tersedia dari data historis (Truong dan Novák, 2023). Peramalan kuantitatif, khususnya pada data jangka pendek dan menengah, sangat bergantung pada identifikasi, pemodelan, dan ekstrapolasi pola yang ditemukan dalam data historis tersebut untuk mendukung pengambilan keputusan strategis, seperti perencanaan pendapatan dan operasional manajemen (Montgomery dan Jennings, 2024).

Sebuah deret waktu umumnya diasumsikan terdekomposisi menjadi empat komponen utama yang membentuk struktur data tersebut. Komponen-komponen tersebut meliputi tren (*trend*) yang mencerminkan perubahan jangka panjang, siklus (*cycle*), musiman (*seasonality*) yang menunjukkan fluktuasi berulang pada periode tertentu, serta gangguan acak (*random noise*) yang tidak terstruktur (Truong dan Novák, 2023). Dalam industri perhotelan, pemahaman terhadap komponen musiman (*seasonality*) dan tren menjadi sangat krusial karena harga dan permintaan kamar sering kali berfluktuasi mengikuti pola waktu tertentu, seperti musim liburan atau periode *high season*. Persamaan dekomposisi deret waktu dapat dinyatakan dalam Persamaan 2.2 (Truong dan Novák, 2023).

$$X(t) = Tr(t) + C(t) + S(t) + R(t) \tag{2.2}$$

Keterangan:

$X(t)$ = Nilai deret waktu pada saat t

$Tr(t)$ = Komponen tren (*trend*)
$C(t)$ = Komponen siklus (*cycle*)
$S(t)$ = Komponen musiman (*seasonality*)
$R(t)$ = Komponen acak (*random noise*)

Penerapan metode *machine learning* pada data deret waktu memerlukan transformasi data untuk menangkap pola ketergantungan waktu atau autokorelasi. Autokorelasi terjadi ketika nilai di atas rata-rata jangka panjang cenderung diikuti oleh nilai lain di atas rata-rata, dan sebaliknya (Montgomery dan Jennings, 2024). Untuk memodelkan fenomena ini dalam kerangka *supervised learning*, digunakan teknik *feature engineering* berupa variabel *Lag* (menggunakan data masa lalu sebagai fitur) dan *Rolling Window* (rata-rata bergerak). Pendekatan ini memungkinkan model untuk mempelajari pola historis harga kamar berdasarkan *property_id* dan *room_id* guna menghasilkan prediksi harga rata-rata bulanan yang akurat di masa mendatang.

2.2.3 Decision Tree

Decision Tree merupakan model *supervised machine learning* yang berfungsi untuk memetakan fitur input ke dalam satu atau lebih variabel hasil (*outcome variables*) yang diinginkan. Tujuan utama dari model ini adalah untuk meminimalkan fungsi kerugian (*loss function*), yang mendeskripsikan bagaimana model mengukur perbedaan antara nilai hasil prediksi dengan nilai aktualnya. Struktur *Decision Tree* terdiri dari serangkaian pertanyaan biner ("ya atau tidak") yang didasarkan pada ambang batas (*cutoff thresholds*) tertentu. Setiap pemisahan (*split*) dalam pohon bertujuan untuk meminimalkan kriteria yang telah ditentukan oleh algoritma tersebut [1].

Mekanisme alur keputusan dalam pohon ini bekerja berdasarkan kondisi pertidaksamaan; jika kondisi terpenuhi, observasi akan berlanjut ke langkah berikutnya di sisi kiri, sedangkan jika tidak, observasi akan bergerak ke sisi kanan. Dalam struktur pohon, langkah terakhir disebut sebagai *leaf* (daun), sementara jika masih terdapat pemisahan berikutnya, titik tersebut disebut sebagai *node*. Setiap

leaf diasosiasikan dengan sebuah nilai, yang menjadi output bagi observasi yang jatuh ke dalam *leaf* tersebut. Oleh karena itu, keputusan yang dimulai dari *root node* (titik awal) hingga mencapai *leaf* menggambarkan bagaimana sebuah keputusan spesifik dicapai, dan urutan keputusan ini dikenal sebagai jalur (*path*). Selain itu, panjang jalur terpanjang dari *root node* ke *leaf node* disebut sebagai kedalaman (*depth*) dari *decision tree* (Gonçalves Carvalho, 2025).

Secara matematis, setiap node Q_i dicapai dari sekumpulan keputusan s_j, yang dapat dinyatakan dalam Persamaan (2.3) berikut:

$$Q_i(\theta) = \bigcap_{j=0}^{i} s_j(\theta) \tag{2.3}$$

Di mana θ adalah sekumpulan parameter yang mendeskripsikan *decision tree*. Konsekuensinya, pohon tersebut bertindak sebagai fungsi prediktor $h(x)$ dari keluarga fungsi $h(x; \theta)$, dengan tujuan meminimalkan kriteria tertentu pada setiap node. Meskipun *decision tree* adalah model yang sederhana, model ini dapat dikombinasikan untuk membentuk model unik menggunakan teknik *bagging* atau *boosting*, yang menciptakan algoritma *ensemble*. Dalam algoritma *bagging*, beberapa model dilatih secara bersamaan, sedangkan dalam *boosting*, proses pelatihan dilakukan secara sekuensial atau bertahap (Gonçalves & Carvalho, 2025).

2.2.4 Gradient Boosting

Gradient Boosting adalah teknik *machine learning* yang berakar pada konsep *ensemble learning*, di mana beberapa model prediksi sederhana atau *weak learners* digabungkan untuk membentuk satu model prediktif yang kuat. Sebuah *weak learner* didefinisikan sebagai model yang kinerjanya hanya sedikit lebih baik daripada tebakan acak, dan dalam kerangka kerja ini, *decision trees* (pohon keputusan) adalah jenis *base learner* yang paling umum digunakan (Gonçalves dan Carvalho, 2025). Berbeda dengan teknik *bagging* yang membangun pohon secara independen, *Gradient Boosting* membangun model secara sekuesial atau bertahap,

di mana setiap pohon baru ditambahkan untuk memperbaiki kesalahan yang dihasilkan oleh gabungan pohon-pohon sebelumnya.

Pendekatan ini didasarkan pada intuisi bahwa kombinasi dari banyak model lemah dapat menghasilkan model yang sangat akurat dengan cara meminimalkan fungsi kerugian (*loss function*) (Gonçalves dan Carvalho, 2025). Algoritma ini bekerja dengan menerapkan metode *gradient descent* pada ruang fungsi. Dalam konteks regresi untuk memprediksi nilai kontinu seperti harga kamar, fungsi kerugian yang umum digunakan adalah *Mean Squared Error* (MSE). Model berusaha meminimalkan kesalahan prediksi dengan menghitung gradien negatif dari fungsi kerugian terhadap prediksi model saat ini, yang kemudian digunakan sebagai target untuk pohon keputusan berikutnya (Gonçalves dan Carvalho, 2025).

Secara matematis, proses pelatihan *Gradient Boosting* melibatkan dataset pelatihan yang dinotasikan dengan *input* x_i dan variabel target y_i. Algoritma ini beroperasi melalui iterasi untuk menemukan fungsi aproksimasi $\hat{F}(x)$ yang meminimalkan nilai harapan dari fungsi kerugian $L\big(y, F(x)\big)$ (Gonçalves dan Carvalho, 2025). Struktur algoritma dan langkah-langkah matematis dalam *Gradient Boosting* untuk kasus regresi dijelaskan secara rinci melalui tahapan berikut:

1. Inisialisasi Model

Tahap awal dimulai dengan menginisialisasi model dengan nilai konstan $\mathrm{F}_0(\mathrm{x})$. Nilai ini ditentukan dengan mencari nilai γ yang meminimalkan jumlah fungsi kerugian di seluruh data pelatihan. Untuk fungsi kerugian *Mean Squared Error*, nilai ini merupakan rata-rata (mean) dari variabel target aktual.

$$F_0(x) = \arg\min_{\gamma} \sum_{i=1}^{n} L(y_i, \gamma) \tag{2.4}$$

Dengan $L(y_i, \gamma)$ adalah fungsi kerugian (*loss function*), γ merupakan nilai prediksi, dan y_i adalah nilai sebenarnya (*true value*).

2. Proses Iteratif

Proses pembangunan pohon dilakukan secara berulang dari $m = 1$ hingga M, di mana M adalah jumlah total pohon yang akan dibangun (misalnya 100 pohon). Langkah ini terdiri dari empat sub-tahapan utama:

A. Perhitungan *Pseudo-Residuals*

Pada setiap iterasi m, dihitung nilai *pseudo-residuals* (r_{im}). Nilai ini merupakan turunan negatif (gradien) dari fungsi kerugian terhadap nilai prediksi sebelumnya. Jika fungsi kerugian diasumsikan sebagai $\frac{1}{2}(Actual - Predicted)^2$, maka turunannya adalah $-(Actual - Predicted)$, sehingga r_{im} merepresentasikan selisih antara nilai aktual dan prediksi.

$$r_{im} = -\left[\frac{\partial L\big(y_i, F(x_i)\big)}{\partial F(x_i)}\right]_{F(x)=F_{m-1}(x)} \tag{2.5}$$

Keterangan:

i = Indeks baris data (1 sampai n)

m = Iterasi *boosting* ke-m

n = Jumlah seluruh data observasi

y_i = Nilai aktual variabel dependen

$F_{m-1}(x)$ = Fungsi prediksi dari gabungan pohon sebelumnya

r_{im} = *Pseudo-residual*

B. Pembentukan *Regression Tree*

Sebuah pohon regresi baru dibangun untuk memprediksi nilai *pseudo-residuals* (r_{im}) tersebut, bukan memprediksi nilai aktual y_i. Pohon ini dibangun menggunakan pendekatan *greedy* untuk membagi ruang input menjadi wilayah terminal (*leaf nodes*) yang disimbolkan dengan R_{jm}, di mana j adalah indeks untuk setiap *leaf node*.

C. Penentuan Nilai Output *Leaf Node*

Untuk setiap wilayah terminal R_{jm}, dihitung nilai output γ_{jm} yang meminimalkan fungsi kerugian. Langkah ini mirip dengan Langkah 1, namun perhitungan hanya dilakukan pada sampel data yang masuk ke dalam *leaf node* tersebut $\left(x_i \in R_{jm}\right)$ dan memperhitungkan prediksi dari pohon sebelumnya.

$$\gamma_{jm} = \arg\min_{\gamma} \sum_{x_i \in R_{jm}} L\left(y_i, F_{(m-1)}(x_i) + \gamma\right) \tag{2.6}$$

D. Pembaruan Model (*Update Model*)

Model prediksi diperbarui dengan menambahkan kontribusi dari pohon baru yang telah diskalakan oleh *learning rate* (ν). *Learning rate* berfungsi untuk mengontrol besaran koreksi yang diberikan oleh setiap pohon guna mencegah *overfitting*.

$$F_m(x) = F_{m-1}(x) + \nu \sum_{j=1}^{J_m} \gamma_{jm} I\left(x \in R_{jm}\right) \tag{2.7}$$

Proses ini diulang hingga jumlah iterasi M tercapai, menghasilkan model akhir $F_M(x)$ yang merupakan kombinasi aditif dari seluruh pohon yang telah dibangun (Gonçalves dan Carvalho, 2025).

2.2.5 *Light Gradient Boosting Machine* (LightGBM)

Light Gradient Boosting Machine (LightGBM) merupakan sebuah kerangka kerja peningkatan gradien (*gradient boosting*) yang menggunakan algoritma pembelajaran berbasis pohon keputusan (*decision tree*). Algoritma ini dikembangkan untuk memiliki kecepatan pelatihan yang lebih tinggi dan efisiensi memori yang lebih baik dibandingkan dengan algoritma *boosting* konvensional (Indah dkk, 2025). Berbeda dengan algoritma pohon keputusan tradisional yang menumbuhkan pohon secara *level-wise* (melebar), LightGBM menerapkan strategi pertumbuhan *leaf-wise* (mendalam pada daun). Strategi ini memilih daun dengan *max delta loss* untuk tumbuh, yang memungkinkan model untuk meminimalkan fungsi kerugian (*loss function*) secara lebih signifikan dan akurat pada dataset yang besar.

Dalam proses pembelajarannya, pengklasifikasi dasar (*basic classifiers*) dengan pohon keputusan dihasilkan selama proses pelatihan, dan parameter bobot dihitung untuk setiap pengklasifikasi dalam iterasi. Model matematis dari integrasi pengklasifikasi ini dapat dinyatakan dalam Persamaan 2.8 berikut:

$$f_m(X) = \partial_1 f_1(X) + \partial_2 f_2(X) + \cdots + \partial_m f_m(X) \quad (2.8)$$

Seluruh pengklasifikasi dasar dan bobot parameternya kemudian diintegrasikan untuk membentuk model akhir seperti yang terlihat pada Persamaan 2.8. Pada persamaan tersebut, $f_m(X)$ merepresentasikan pengklasifikasi dasar (*base classifier*) dan ∂_m mewakili parameter bobot dari setiap pengklasifikasi (Indah dkk, 2025).

Guna menangani jumlah data yang besar dan dimensi fitur yang tinggi, LightGBM memperkenalkan dua teknik optimasi novel, yaitu *Gradient-based One-Side Sampling* (GOSS) dan *Exclusive Feature Bundling* (EFB). GOSS bekerja dengan mempertahankan semua instansi data yang memiliki nilai gradien (residual) besar sembari melakukan pengambilan sampel secara acak pada data dengan gradien kecil, sehingga prioritas pelatihan diberikan pada data yang belum termodelkan dengan baik atau *under-trained* (Gonçalves dan Carvalho, 2025). Sementara itu, EFB digunakan untuk menggabungkan fitur-fitur eksklusif (fitur yang tidak pernah bernilai bukan nol secara bersamaan) menjadi satu fitur tunggal. Penggabungan ini dapat mengurangi waktu pemrosesan secara signifikan dalam ruang fitur yang jarang (*sparse feature space*) tanpa mengurangi akurasi prediksi secara drastis (Gonçalves dan Carvalho, 2025).

2.2.6 Evaluasi Kinerja Model

Evaluasi kinerja model merupakan tahapan krusial dalam pembangunan sistem peramalan (*forecasting*) harga kamar untuk memastikan validitas dan keandalan hasil prediksi. Dalam penelitian ini, model LightGBM yang dibangun untuk memprediksi rata-rata harga kamar berdasarkan *property_id* dan *room_id* akan dievaluasi menggunakan beberapa metrik statistik standar. Penggunaan metrik evaluasi bertujuan untuk mengukur seberapa dekat nilai prediksi harga yang dihasilkan oleh model dengan data harga aktual yang terdapat pada saluran pemesanan Booking.com. Metrik yang digunakan meliputi *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), *R-Squared* (R^2 Score), dan *Mean Absolute Percentage Error* (MAPE).

1. *Mean Absolute Error* (MAE)

Mean Absolute Error (MAE) digunakan untuk menghitung rata-rata kesalahan antara hasil aktual dan hasil prediksi dalam pemodelan. Nilai MAE merepresentasikan besarnya kesalahan rata-rata dalam satuan yang sama dengan data asli tanpa memperhatikan arah kesalahan (positif atau negatif) (Sanjaya, 2024). Perumusan dari *Mean Absolute Error* (MAE) ditunjukkan pada Persamaan 2.9.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{2.9}$$

Keterangan:

- $\hat{y}_i$: Nilai hasil prediksi harga
- y_i : Nilai aktual harga
- n : Jumlah data sampel

2. *Mean Squared Error* (MSE)

Mean Squared Error (MSE) memperkirakan akurasi dengan cara mengukur kerugian kuadrat berdasarkan perbedaan antara nilai aktual dan prediksi. Metode ini memberikan bobot yang lebih besar pada kesalahan yang besar karena adanya proses pengkuadratan selisih nilai, sehingga sensitif terhadap *outlier* atau data pencilan (Sanjaya, 2024). Perumusan dari *Mean Squared Error* (MSE) dapat dilihat pada Persamaan 2.10.

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{2.10}$$

Keterangan:

- n : Jumlah data pengamatan
- y_i : Nilai aktual harga
- $\hat{y}_i$: Nilai hasil prediksi harga

3. Root Mean Squared Error (RMSE)

Root Mean Squared Error (RMSE) adalah metode untuk mengevaluasi kualitas suatu model berdasarkan kesalahan dalam estimasi. Kesalahan yang diukur

menunjukkan seberapa jauh hasil estimasi dari nilai yang sebenarnya, di mana RMSE merupakan akar kuadrat dari MSE untuk mengembalikan satuan kesalahan ke bentuk aslinya (Sanjaya, 2024). Perhitungan RMSE dilakukan dengan menggunakan rumus pada Persamaan 2.11.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{2.11}$$

Keterangan:

- n : Jumlah data pengamatan
- y_i : Nilai aktual harga
- $\hat{y}_i$: Nilai hasil prediksi harga

4. *R-Squared* (R^2 Score)

R^2 *Score* atau Koefisien Determinasi adalah metode yang digunakan untuk mengevaluasi seberapa baik variabel independen dapat menjelaskan variabilitas variabel dependen melalui pengujian koefisien determinasi. Koefisien ini memiliki nilai antara 0 dan 1, di mana nilai 1 menunjukkan hubungan yang kuat dan kemampuan prediksi yang sempurna antara variabel dependen dan independen (Sanjaya, 2024). Rumus untuk menghitung R^2 *Score* ditunjukkan pada Persamaan 2.12.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{2.12}$$

Keterangan:

- y_i : Nilai yang diamati (aktual) untuk pengamatan ke-i
- $\hat{y}_i$: Nilai yang diramalkan (prediksi) untuk pengamatan ke-i
- $\bar{y}$: Rata-rata dari nilai yang diamati

5. *Mean Absolute Percentage Error* (MAPE)

Mean Absolute Percentage Error (MAPE) digunakan untuk mengukur rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual. MAPE sangat

intuitif untuk diinterpretasikan dalam konteks bisnis, di mana nilai persentase yang lebih kecil menunjukkan hasil prediksi model yang lebih akurat (Raafi Herlando dkk., 2025). Rumus perhitungan MAPE ditunjukkan pada Persamaan 2.13.

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \widehat{y_i}}{y_i}\right| \times 100\% \tag{2.13}$$

Keterangan:

- y_i : Nilai aktual data ke-i
- $\widehat{y_i}$: Nilai prediksi data ke-i
- n : Jumlah data

BAB III
TINJAUAN UMUM INSTANSI

3.1 Gambaran Umum

3.2 Struktur Organisasi

3.3 Proses Bisnis / Business Rule

BAB IV
METODE KERJA PRAKTIK

4.1 Tahapan Kerja Praktik

Tahapan kerja praktik menyebutkan dan menjelaskan langkah-langkah yang akan dijalankan secara detail dalam kerja praktik yang telah atau akan dilakukan. Penjelasan dapat menggunakan diagram yang dapat menggambarkan langkah-langkah kerja praktik serupa dengan tahapan atau metode pengembangan sistem. Perancangan dapat dituangkan kedalam perancangan sederhana (model proses ataupun model data).

Adapun alur tahapan penelitian yang dirancang untuk menyelesaikan permasalahan prediksi harga kamar rata-rata ini digambarkan dalam diagram alir pada Gambar 4.1.

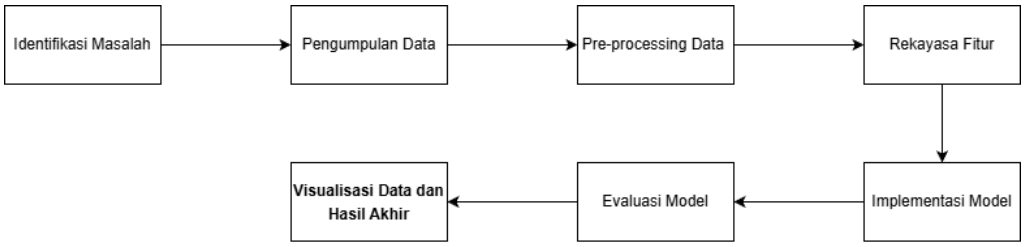

Gambar 4.1 Tahapan Kerja Praktik

Berikut adalah uraian mendetail mengenai tahapan-tahapan yang dilakukan dalam penelitian ini:

4.1.1 Identifikasi Masalah

Tahap ini merupakan langkah awal untuk memahami konteks bisnis dan permasalahan yang dihadapi oleh PT Genius Utama Indonesia (Genius Hospitality Management). Identifikasi difokuskan pada kesulitan manajemen dalam menentukan strategi harga yang tepat akibat fluktuasi permintaan dan variabilitas karakteristik antar properti. Masalah didefinisikan secara spesifik, yaitu perlunya sebuah model yang mampu memprediksi rata-rata harga kamar (*Average Room Rate*) per bulan untuk setiap tipe kamar (*room_id*) pada masing-masing properti (*property_id*) di masa mendatang guna mendukung keputusan *dynamic pricing*.

4.1.2 Pengumpulan Data

Pengumpulan data dilakukan dengan mengekstraksi data transaksi historis dari *database* internal perusahaan. Mengingat adanya inkonsistensi data pada berbagai saluran pemasaran, pengambilan data dibatasi secara eksklusif pada saluran *Booking.com*. Data yang dikumpulkan mencakup variabel-variabel krusial seperti nomor pemesanan (*booking_id*), identitas properti (*property_id*), identitas tipe kamar (*room_id*), tanggal pemesanan (*booking_time*), harga (*price*), jumlah tamu dewasa (*num_adult*), dan jumlah anak (*num_child*). Data ini akan menjadi basis utama dalam proses pembelajaran model.

4.1.3 Pre-processing Data

Pre-processing data adalah proses yang dilakukan sebelum proses penelitian demi mendapatkan data yang layak untuk digunakan. Mengingat data mentah berupa data transaksi harian, tahapan ini sangat krusial dan meliputi langkah-langkah berikut:

1. **Pembersihan Data (*Data Cleaning*):** Dilakukan penyaringan (*filtering*) untuk memastikan hanya data dengan status saluran *Booking.com* yang diproses. Data dengan nilai yang hilang atau anomali yang tidak dapat diperbaiki akan dihapus atau disesuaikan.
2. **Konversi Tipe Data:** Variabel waktu seperti *booking_time* dikonversi menjadi format *datetime* untuk memungkinkan pengolahan deret waktu (*time series*). Variabel kategorikal seperti *property_id* dan *room_id* dipastikan formatnya untuk proses pengelompokan.
3. **Agregasi Data (*Data Aggregation*):** Data transaksi diubah menjadi data deret waktu bulanan. Dilakukan pengelompokan berdasarkan *property_id*, *room_id*, dan periode bulan (*month_date*). Variabel target *price* dihitung nilai rata-ratanya (*mean*), sedangkan variabel lain seperti jumlah tamu dan jumlah pemesanan dihitung totalnya (*sum* atau *count*).
4. **Penanganan *Missing Values*:** Untuk menjaga kontinuitas deret waktu, data harga yang kosong pada bulan tertentu diisi menggunakan metode imputasi *forward fill* dan *backward fill*, dengan asumsi harga cenderung stabil dalam periode yang berdekatan.

4.1.4 Rekayasa Fitur (Feature Engineering)

Tahapan ini bertujuan untuk menciptakan fitur-fitur baru yang dapat meningkatkan kemampuan prediksi model *machine learning*. Proses ini dilakukan dengan mentransformasi data deret waktu yang telah diagregasi. Beberapa fitur yang dibentuk meliputi:

1. **Fitur Kalender:** Ekstraksi informasi waktu seperti tahun, bulan, dan kuartal dari variabel tanggal.
2. **Penyandian Fitur Kategorikal (*Encoding*):** Variabel *property_id* dan *room_id* diubah menjadi bentuk numerik menggunakan teknik *Label Encoding* agar dapat diproses oleh algoritma.
3. **Fitur *Lag* dan *Rolling Window*:** Pembuatan fitur berdasarkan data historis, seperti harga pada bulan sebelumnya (*lag_1*), harga dua bulan sebelumnya (*lag_2*), hingga harga tahun sebelumnya (*lag_12*). Selain itu, dihitung rata-rata bergerak (*rolling mean*) untuk menangkap tren jangka pendek, misalnya rata-rata harga dalam 3 bulan atau 6 bulan terakhir. Fitur ini memungkinkan model mempelajari pola autokorelasi pada data harga.

4.1.5 Implementasi Model

Implementasi model adalah proses penerapan model *machine learning* dalam sebuah penelitian untuk membangun algoritma yang dapat melakukan peramalan. Pada penelitian ini, algoritma yang digunakan adalah *Light Gradient Boosting Machine* (LightGBM). Data yang telah melalui proses rekayasa fitur dibagi menjadi data latih (*training set*) dan data uji (*testing set*) berdasarkan urutan waktu. Model dilatih untuk mempelajari pola hubungan antara fitur-fitur historis (*property_id*, *room_id*, *lags*, dll.) dengan target variabel yaitu rata-rata harga kamar (*price*).

4.1.6 Evaluasi Model

Setelah model dilatih, dilakukan tahap evaluasi untuk mengukur kinerja dan akurasi prediksi model. Evaluasi dilakukan dengan membandingkan hasil prediksi model terhadap data aktual pada data uji. Metrik evaluasi yang digunakan meliputi *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE). Hasil evaluasi ini

akan menentukan apakah model sudah cukup akurat untuk diimplementasikan atau memerlukan penyesuaian parameter lebih lanjut.

4.1.7 Visualisasi Data dan Hasil Akhir

Hasil akhir dari keseluruhan proses akan menjadi kesimpulan dan menjawab masalah yang sudah teridentifikasi di awal. Pada tahap ini, hasil prediksi divisualisasikan dalam bentuk grafik perbandingan antara harga aktual dan harga prediksi (*Actual vs Predicted*) untuk setiap tipe kamar dan properti. Visualisasi ini bertujuan untuk memudahkan manajemen Genius Hospitality Management dalam memahami performa model. Hasil akhir ini akan disampaikan kepada instansi terkait sebagai bentuk pertanggungjawaban penelitian serta rekomendasi untuk strategi penetapan harga di masa mendatang.

4.2 Data

Proses pengumpulan data bertujuan untuk memperoleh informasi yang komprehensif sebagai basis utama dalam pembangunan model peramalan. Data yang digunakan dalam penelitian ini diklasifikasikan sebagai data sekunder, yang meliputi:

1. Data transaksi historis pemesanan kamar yang diperoleh melalui ekstraksi *Application Programming Interface* (API) dari sistem manajemen properti beds24.com. Data ini dibatasi pada saluran Booking.com dan mencakup variabel krusial seperti identitas properti (*property_id*), tipe kamar (*room_id*), waktu pemesanan (*booking_time*), serta harga (*price*).
2. Data informasi musiman (*seasonality*) hotel yang diperoleh dari dokumentasi internal perusahaan. Data ini memuat informasi periode *Low Season*, *Mid-Season*, *High Season*, hingga *Peak Season* yang berfungsi sebagai *domain knowledge* untuk analisis tren.

4.3 Jadwal Kerja Praktik

Jadwal kerja praktik disusun sebagai acuan estimasi waktu pelaksanaan penelitian agar berjalan sistematis dan sesuai dengan tahapan yang direncanakan. Rincian jadwal kegiatan penelitian ini disajikan pada Tabel 4.1.

Tabel 4.1 Jadwal Kerja Praktik

Kegiatan	**Sep. 2025**	**Okt. 2025**	**Nov. 2025**	**Des. 2025**	**Jan. 2026**
Identifikasi Masalah					
Pengumpulan Data					
Pre-processing Data					
Rekayasa Fitur (*Feature Engineering*)					
Implementasi Model					
Evaluasi Model					
Visualisasi Data dan Hasil Akhir					
Penyusunan Naskah Laporan:					
• BAB I dan BAB II					
• BAB III					
• BAB IV					
• BAB V					
• BAB VI					

BAB V
DAFTAR PUSTAKA

BAB VILAMPIRAN