Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer e-ISSN: 2548-964X
Vol. 9, No. 6, Juni 2025, hlm. x-x http://j-ptiik.ub.ac.id

ANALISIS PERBANDINGAN MACHINE LEARNING UNTUK MEMPREDIKSI HARGA MINYAK DENGAN REGRESI LINEAR DAN SUPPORT VECTOR REGRESSION

Muhammad Raafi Herlando[1], Satrio Hadi Wijoyo[2], Muhammad Aminul Akbar[3]

Program Studi Sistem Informasi, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: [1]mraafiherlando.student@ub.ac.id, [2]satriohadi@ub.ac.id, [3]muhammad.aminul@ub.ac.id

Abstrak

Tingginya volatilitas harga minyak mentah Brent menjadi tantangan signifikan bagi perencanaan keuangan perusahaan. Penelitian ini bertujuan membangun dan membandingkan model prediksi harga minyak bulanan menggunakan Regresi Linear dan *Support Vector Regression* (SVR), dengan variabel prediktor berupa data historis harga emas dan kurs mata uang. Metodologi penelitian mencakup pra-pemrosesan data, rekayasa fitur deret waktu, dan pengujian model pada empat skenario rentang waktu yang berbeda. Kinerja model dievaluasi menggunakan metrik R-squared (R^2), RMSE, dan MAPE. Hasil penelitian menunjukkan bahwa kedua model gagal menghasilkan prediksi yang akurat, dibuktikan dengan nilai R^2 yang mayoritas negatif. Satu-satunya anomali adalah model Regresi Linear pada skenario 7 tahun yang mencapai R^2 sebesar 0.2442 dan MAPE 5.38% Dalam perbandingan langsung, Regresi Linear secara konsisten berkinerja lebih baik SVR. Kesimpulan utamanya adalah variabel makroekonomi yang digunakan tidak memiliki daya prediksi yang kuat untuk pasar minyak yang kompleks. Hasil ini mengimplikasikan perlunya eksplorasi fitur yang lebih spesifik pada industri energi dan arsitektur model yang lebih canggih untuk prediksi yang akurat.

Kata kunci: *prediksi harga minyak, machine learning, regresi linear, support vector regression (SVR), koefisien determinasi (R^2)*

Abstract

The high volatility of Brent crude oil prices poses a significant challenge to corporate financial planning. This research aims to develop and compare predictive models for monthly oil prices using Linear Regression and Support Vector Regression (SVR), utilizing historical gold prices and currency exchange rates as predictor variables. The methodology involved data preprocessing, time-series feature engineering, and model testing across four different time-range scenarios, with performance evaluated using R-squared (R^2), RMSE, and MAPE metrics. The results show that both tested models failed to produce accurate and reliable predictions, evidenced by predominantly negative R^2 values. The only anomaly was the Linear Regression model in the 7-year scenario, which achieved an R^2 of 0.2442 and MAPE 5,38%. In direct comparison, Linear Regression consistently performed better than SVR. The main conclusion is that the selected macroeconomic variables lack sufficient predictive power to model the complex oil market. This failure implies that for accurate forecasting, exploration of more energy-industry-specific features and potentially more advanced model architectures is necessary.

Keywords: *oil price prediction, machine learning, linear regression, support vector regression (SVR), coefficient of determination (R^2)*

1. PENDAHULUAN

Industri minyak memegang peranan krusial dalam perekonomian global, namun harganya yang sangat fluktuatif menjadi tantangan besar bagi pelaku industri dalam pengambilan keputusan strategis. Ketidakstabilan ini dipengaruhi oleh berbagai faktor kompleks seperti dinamika pasar, kondisi geopolitik, dan indikator makroekonomi (Arifin, 2018). Untuk mengatasi tantangan ini, pendekatan *machine learning* mulai banyak dimanfaatkan karena potensinya dalam menawarkan akurasi yang lebih tinggi dibandingkan metode konvensional (Qirani & Sukarsih, 2024). Namun, banyak studi cenderung berfokus pada model yang sangat

kompleks seperti *deep learning*, yang memerlukan sumber daya komputasi tinggi. Terdapat kesenjangan dalam evaluasi komparatif metode yang lebih sederhana namun efektif untuk konteks industri.

Penelitian ini bertujuan untuk mengisi kesenjangan tersebut dengan menganalisis dan membandingkan performa dua model *machine learning* yang populer: Regresi Linear dan *Support Vector Regression* (SVR). Regresi Linear dipilih karena kesederhanaannya, sementara SVR dipilih karena kemampuannya menangani pola non-linier yang umum pada data harga minyak (Hussein & Azhar, 2021). Penelitian ini menguji kedua model pada beberapa rentang data historis untuk mengevaluasi konsistensi dan validitasnya. Metode yang digunakan mencakup pengumpulan data sekunder, pra-pemrosesan, pemodelan, dan evaluasi menggunakan metrik R^2, RMSE, dan MAPE. Tujuan utamanya adalah untuk menentukan apakah model-model ini, dengan variabel prediktor yang dipilih, dapat menjadi alat yang andal untuk prediksi harga minyak dalam konteks perusahaan seperti PT. XYZ.

2. LANDASAN KEPUSTAKAAN

2.1 Kajian Pustaka

Prediksi harga minyak merupakan tugas yang kompleks karena sifat datanya yang volatil dan dipengaruhi oleh banyak faktor. Pendekatan *machine learning* menjadi populer karena kemampuannya menangkap pola non-linier yang tidak dapat diatasi oleh model ekonometrika konvensional (Hussein & Azhar, 2021). Beberapa penelitian terdahulu telah membandingkan berbagai model *supervised learning* untuk menentukan metode terbaik, termasuk SVR, Random Forest, dan Regresi Linear (Keerthan et al., 2019). Studi lain juga menunjukkan bahwa *machine learning* terbukti lebih akurat dalam memprediksi volatilitas harga dibandingkan model tradisional (Kim et al., 2020).

2.2 Regresi Linear

Regresi Linear adalah metode statistik fundamental yang digunakan untuk memodelkan hubungan linier antara variabel dependen dan independen. Karena kesederhanaan interpretasinya, metode ini sering digunakan sebagai model dasar (*baseline*) untuk perbandingan (James et al., 2013). Model regresi linear dapat direpresentasikan dengan persamaan (1).

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \varepsilon \quad (1)$$

Di mana y adalah variabel dependen, X_n adalah variabel independen, β_n adalah koefisien regresi, dan ε adalah galat (Wooldridge, 2013).

2.3 Support Vector Regression

Support Vector Regression (SVR) merupakan pengembangan dari *Support Vector Machine* yang dirancang untuk tugas regresi. Prinsip utama SVR adalah menemukan fungsi prediksi dengan margin kesalahan minimal terhadap nilai aktual dalam batas toleransi tertentu (ε). Keunggulan utama SVR terletak pada penggunaan fungsi kernel, seperti *Radial Basis Function* (RBF), yang memungkinkannya memodelkan hubungan non-linier yang kompleks secara efektif (Smola & Schölkopf, 2004). Fungsi objektif SVR adalah sebagai berikut:

$$\min_{w,b,\xi,\xi^*} \frac{1}{2}|w|^2 + C\sum_{\{i=1\}}^{n}(\xi_i + \xi_i^*) \quad (2)$$

Fungsi kernel RBF yang digunakan dalam penelitian ini dapat dilihat pada persamaan (3).

$$K(x_i, x_j) = \exp(-\gamma||x_i - x_j||^2) \quad (3)$$

2.4 Evaluasi Model Prediksi

Untuk menilai kinerja model prediksi, digunakan beberapa metrik evaluasi standar. Setiap metrik memberikan perspektif yang berbeda terhadap kinerja model. Koefisien Determinasi (R^2) merupakan metrik yang mengukur proporsi variasi dalam variabel target yang dapat dijelaskan oleh model (Kutner et al., 2005). Nilai berkisar antara 0 dan 1, di mana nilai yang mendekati 1 menunjukkan model yang baik. Rumusnya adalah sebagai berikut:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \quad (4)$$

Root Mean Squared Error (RMSE) sebagai metrik yang menghitung akar kuadrat dari rata-rata kuadrat selisih antara nilai aktual dan prediksi. RMSE sangat sensitif terhadap kesalahan besar dan memberikan gambaran magnitudo kesalahan dalam satuan yang sama dengan data target (Chai & Draxler, 2014).

$$RMSE = \sqrt{\frac{1}{n} \times \sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \quad (5)$$

Mean Absolute Percentage Error (MAPE)

mengukur rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual. MAPE sangat intuitif untuk diinterpretasikan, di mana nilai yang lebih kecil menunjukkan prediksi yang lebih akurat (Makridakis, Wheelwright, & Hyndman, 1998).

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{(y_i - \hat{y}_i)}{y_i}\right| \times 100\% \quad (6)$$

2.5 Bahasa Pemrograman Pyhton

Python adalah bahasa pemrograman tingkat tinggi yang dirancang dengan penekanan pada keterbacaan kode dan kemudahan penggunaan (Van Rossum & Drake, 2006). Dikembangkan oleh Guido van Rossum, Python telah menjadi salah satu bahasa paling populer di dunia, terutama dalam bidang ilmu data dan *machine learning*. Keunggulannya terletak pada sintaksis yang bersih, komunitas global yang aktif, dan ekosistem pustaka (*library*) yang sangat luas. Untuk keperluan analisis data dan pemodelan, penelitian ini memanfaatkan beberapa pustaka kunci, yaitu Pandas untuk manipulasi data, NumPy untuk komputasi numerik, Matplotlib untuk visualisasi, serta Scikit-learn sebagai fondasi implementasi model *machine learning* (Pedregosa et al., 2011).

3. METODOLOGI PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif implementatif dengan alur kerja yang sistematis. Secara umum, tahapan penelitian dimulai dari studi literatur, pengumpulan data, pemrosesan data, pembuatan model Regresi Linear dan SVR, evaluasi model, hingga penarikan kesimpulan.

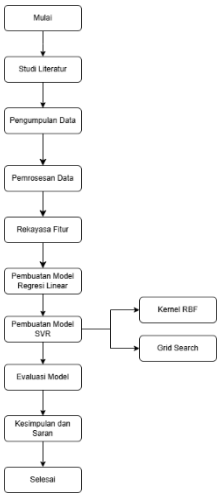

Gambar 1. Diagram Alur Metodologi Penelitian

Pada Gambar 1 menjelaskan secara lebih rinci, alur implementasi model yang digunakan menyoroti perbedaan fundamental antara proses pelatihan kedua model. Jalur untuk Regresi Linear digambarkan sebagai proses pencocokan langsung yang lebih sederhana untuk menemukan hubungan linear. Sebaliknya, jalur SVR menunjukkan proses yang lebih kompleks, yang melibatkan optimasi *hyperparameter* menggunakan *Grid Search* dan penerapan mekanisme Kernel RBF untuk menangkap pola non-linear.

Tahap-tahap ini kemudian dilanjutkan dengan langkah-langkah spesifik sebagai berikut. pengumpulan data sekunder berjenis kuantitatif runtun waktu bulanan dari Mei 2015 hingga Mei 2025. Data Harga Minyak Mentah Brent bersumber dari U.S. Energy Information Administration (EIA), sementara data pendukung (Harga Emas, kurs USD/IDR, EUR/IDR) berasal dari Investing.com. Tahap selanjutnya adalah pra-pemrosesan data untuk memastikan kualitas (Han, Pei, & Kamber, 2011) , yang mencakup pembersihan, konversi tipe data, dan penggabungan menggunakan Pandas. Kemudian, dilakukan rekayasa fitur untuk memberikan konteks historis pada model. Fitur yang dibuat meliputi nilai *lag* harga minyak (1, 3, dan 12 bulan), *moving average* (3 dan 12 bulan), serta fitur waktu (bulan dan tahun). Kerangka pengujian empiris diadopsi dengan menguji model pada empat rentang waktu historis (3, 5, 7, dan 10 tahun) untuk melihat pengaruh panjang data. Untuk setiap skenario, data dibagi menjadi 80% data latih dan 20% data uji secara kronologis (Hyndman & Athanasopoulos, 2018). Model Regresi Linear dilatih secara langsung, sementara untuk SVR, optimasi hiperparameter dilakukan menggunakan GridSearchCV. Kinerja model yang telah terlatih kemudian dievaluasi pada data uji menggunakan metrik R^2, RMSE, dan MAPE.

4. HASIL DAN PEMBAHASAN

Penelitian ini menyajikan temuan utama yang diperoleh dari implementasi metodologi penelitian yang telah diuraikan. Pembahasan mencakup rincian perangkat yang digunakan, hasil pengolahan data, serta evaluasi kuantitatif dan analisis visual terhadap kinerja model Regresi Linear dan Support Vector Regression (SVR) dalam memprediksi harga minyak.

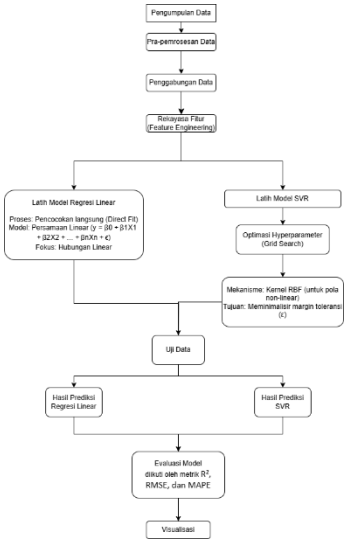

Gambar 2. Alur Implementasi Model

Pada Gambar 2 memvisualisasikan flowchart mengenai perbedaan mendasar antara proses pemodelan Regresi Linear dan SVR dalam satu alur kerja yang terintegrasi. Meskipun tahap awal seperti pengumpulan, pra-pemrosesan, dan penggabungan data, rekayasa fitur serta tahap akhir seperti prediksi dan evaluasi berlaku untuk kedua model, perbedaan signifikan muncul pada tahap pelatihan. Jalur untuk Regresi Linear digambarkan sebagai proses yang lebih sederhana. Fokus utamanya adalah menemukan hubungan linear melalui pencocokan langsung menggunakan persamaan linear standar. Sebaliknya, jalur SVR menunjukkan proses yang jauh lebih kompleks. Sebelum model dilatih, terdapat langkah krusial yaitu Optimasi Hyperparameter menggunakan Grid Search untuk menemukan pengaturan terbaik. Proses peatihannya sendiri menggunakan mekanisme Kernel RBF yang secara spesifik dirancang untuk menangkap pola non-linear dalam data, dengan tujuan meminimalkan error dalam margin toleransi (ε) yang telah dintentukan. Setelah melewati tahap pelatihan yang berbeda secara fundamental ini, kedua alur proses kemudian bersatu kembali untuk tahap prediksi, evaluasi, dan visualisasi kedua model.

4.1 Hasil Pengumpulan Data

Penelitian ini menggunakan data sekunder berjenis kuantitatif dengan struktur runtun waktu (*time series*) yang dicatat dalam interval bulanan, mencakup periode Mei 2015 hingga Mei 2025 untuk memungkinkan pengujian dengan rentang data historis yang bervariasi. Data utama, yaitu Harga Minyak Mentah Brent, bersumber dari U.S. Energy Information Administration (EIA), sementara data komoditas pendukung seperti Harga Emas serta kurs tukar USD/IDR dan EUR/IDR diperoleh dari portal finansial Investing.com. Setelah melalui tahap pra-pemrosesan, dataset final yang digunakan terdiri dari 121 baris data dengan 3 variabel dependen (Harga Emas, USD/IDR, EUR/IDR) dan 1 variabel independen (Harga Minyak).

4.2 Transformasi dan Pra-pemrosesan Data

Tahap transformasi dan pra-pemrosesan data merupakan fondasi dari keseluruhan proses analisis, bertujuan untuk mengubah data mentah dari berbagai sumber menjadi set data yang bersih, terstruktur, dan siap untuk dimodelkan. Kualitas data akan sangat memengaruhi performa model yang dihasilkan, sehingga proses ini tidak boleh diabaikan (Han, Pei, & Kamber, 2011). Proses ini dimulai dengan memproses setiap file CSV secara terpisah untuk memastikan konsistensi format sebelum data dapat digabungkan. Untuk efisiensi, sebuah fungsi kustom clean_currency_csv dibuat di Python, yang bertugas membaca file, memilih kolom 'Date' dan 'Price' yang relevan, mengubah format tanggal, serta membersihkan kolom harga dari karakter non-numerik (seperti koma) sebelum mengubahnya menjadi tipe data numerik (*float*). Sebagai contoh spesifik, pada data harga minyak Brent yang awalnya memiliki format bulan dan tahun seperti terlihat pada Tabel 1, dilakukan serangkaian operasi menggunakan pustaka Pandas. Pertama, fungsi .rename() digunakan untuk mengubah nama kolom 'Month' menjadi 'Date' dan nama kolom harga yang panjang menjadi 'brent_price'. Selanjutnya, fungsi pd.to_datetime() diterapkan untuk mengonversi kolom 'Date' yang semula berformat teks menjadi objek *datetime* yang dapat diproses oleh Python.

Tabel 1. Format Data Bulan/Tahun

1	*Month,Europe Brent Spot Price FOB Dollars per Barrel*
2	Apr 2025,68.13
3	Mar 2025,72.73
4	Feb 2025,75.44
5	Dec 2024,73.86
6	Nov 2024,74.35
7	Oct 2024,75.63
8	Sep 2024,74.02
9	Aug 2024,80.36

Tabel 1, dilakukan serangkaian operasi menggunakan pustaka Pandas. Pertama, fungsi .rename() digunakan untuk mengubah nama kolom 'Month' menjadi 'Date' dan nama kolom harga yang panjang menjadi 'brent_price'. Selanjutnya, fungsi pd.to_datetime() diterapkan untuk mengonversi kolom 'Date' yang semula berformat teks menjadi objek *datetime* yang dapat diproses oleh Python.

Tabel 2. Format Data Bulan/Tanggal/Tahun (Amerika Serikat)

1	*Date,"Price","Open","High","Low","Vol.","Change %"*
2	05/01/2025,"3,315.40","3,312.30","3,460.50","3,139.60","434.65K","-0.52%"
3	04/01/2025,"3,332.70","3,157.30","3,509.90","2,970.40","5.01M","5.79%"
4	03/01/2025,"3,150.30","2,896.10","3,162.00","2,883.20","452.19K","10.07%"
5	02/01/2025,"2,862.20","2,846.50","2,974.00","2,802.20","3.12M","0.96%"
6	01/01/2025,"2,835.00","2,652.00","2,862.90","2,638.90","386.65K","6.85%"
7	12/01/2024,"2,653.30","2,673.80","2,761.30","2,596.70","2.92M","-1.03%"
8	11/01/2024,"2,681.00","2,766.90","2,782.80","2,560.80","360.31K","-2.92%"
9	10/01/2024,"2,761.60","2,656.10","2,813.10","2,618.80","3.63M","4.29%"

Proses serupa dilakukan untuk data lain yang memiliki format tanggal berbeda, seperti Bulan/Tanggal/Tahun terlihat pada Tabel 2. Terakhir, dilakukan pemilihan kolom untuk memastikan hanya kolom 'Date' dan harga yang relevan yang akan dibawa ke tahap penggabungan, sehingga menghasilkan *DataFrame* yang bersih dan fokus.

4.3 Penggabungan dan Finalisasi Data Master

Setelah setiap set data dibersihkan secara individual, langkah berikutnya adalah menggabungkan semuanya menjadi satu tabel utama (*DataFrame*) berdasarkan kolom 'Date' untuk menciptakan data master. Proses ini dilakukan secara berantai menggunakan fungsi pd.merge() dari pustaka Pandas dengan parameter how='outer' untuk memastikan tidak ada data tanggal yang hilang selama proses penggabungan; baris dari setiap tanggal akan dipertahankan meskipun data dari sumber lain tidak tersedia untuk tanggal tersebut, yang akan diisi dengan nilai kosong (NaN). Data yang telah digabung kemudian diurutkan secara kronologis menggunakan .sort_values(by='Date') dan kolom 'Date' dijadikan sebagai indeks DataFrame melalui .set_index('Date'), yang fundamental untuk analisis deret waktu. Terakhir, untuk menangani nilai kosong (NaN) yang mungkin muncul, metode *forward fill* (.fillna(method='ffill')) diterapkan untuk mengisi kekosongan dengan nilai valid terakhir, diikuti oleh .dropna() untuk menghapus sisa baris kosong yang mungkin masih ada di awal dataset, sehingga menghasilkan DataFrame master yang bersih dan lengkap untuk pemodelan.

4.3 Rekayasa Fitur (*Feature Engineering*)

Tahap rekayasa fitur merupakan langkah krusial dalam metodologi penelitian ini, yang bertujuan untuk mentransformasi data deret waktu mentah menjadi sebuah format yang informatif bagi model *machine learning* yang tidak secara inheren memahami dependensi temporal (Hastie et al., 2009). Proses ini diterapkan secara iteratif di dalam setiap skenario pengujian untuk memastikan validitas temporal. Proses ini meliputi penciptaan fitur *lag*, yaitu variabel yang berisi nilai harga minyak dari periode sebelumnya (1, 3, dan 12 bulan) untuk membekali model dengan informasi autoregresif. Selanjutnya, untuk membantu model mengidentifikasi tren yang mendasari data dengan cara menghaluskan fluktuasi jangka pendek, dibuatlah fitur rata-rata pergerakan (*moving average*) dari harga 3 dan 12 bulan terakhir, sebuah teknik yang umum dalam analisis deret waktu (Hyndman & Athanasopoulos, 2018). Terakhir, untuk menangkap potensi pola siklis, diekstrak pula fitur berbasis waktu langsung dari indeks tanggal, seperti bulan dan tahun. Setelah semua fitur baru dibuat, semua baris yang mengandung nilai kosong (NaN) yang dihasilkan dari proses *shift* dan *rolling* akan dihapus untuk menciptakan set data akhir yang valid dan siap untuk pemodelan.

4.3 Implementasi Alur Kerja Pemodelan dengan Python

Bagian ini merinci implementasi teknis dari proses pemodelan yang dilakukan menggunakan skrip Python (predict_oil_price.py). Alur kerja ini mencakup skenario pengujian dan pembagian data, implementasi model *machine learning*, hingga eksekusi prediksi, evaluasi, dan visualisasi hasil.

Penelitian ini menggunakan empat skenario pengujian berdasarkan rentang waktu data historis, yaitu 3 Tahun, 5 Tahun, 7 Tahun, dan 10 Tahun. Untuk setiap skenario, data dibagi dengan metode *hold-out forward* yang valid secara temporal, di mana 80% data awal periode tersebut digunakan sebagai data latih dan 20% sisanya sebagai data uji (Hyndman & Athanasopoulos, 2018).

Implementasi ini dilakukan melalui sebuah *loop* yang beriterasi untuk setiap skenario pengujian. Di dalam *loop*, jumlah bulan (num_months) yang relevan untuk setiap skenario dihitung. Baris kode df_range = df_master.tail(num_months).copy() kemudian secara efisien memilih N baris (bulan) terakhir dari DataFrame master, memastikan analisis selalu menggunakan data historis terkini yang tersedia untuk skenario tersebut. Setelah rekayasa fitur diterapkan pada df_range, titik potong (split_index) dihitung sebagai 80% dari total panjang data. Variabel ini menjadi dasar untuk memisahkan data secara kronologis menggunakan teknik *slicing* [:split_index] untuk data latih dan [split_index:] untuk data uji. Metode ini secara ketat mempertahankan urutan waktu, sebuah langkah esensial untuk mencegah model "melihat masa depan" saat proses pelatihan.

Proses implementasi model *machine learning* difokuskan pada dua algoritma utama: Regresi Linear dan SVR. Untuk Regresi Linear, prosesnya lebih langsung; sebuah *instance* dari model dibuat menggunakan LinearRegression() dan kemudian dilatih secara langsung pada data latih dengan memanggil metode .fit(X_train, y_train). Pada tahap ini, model mempelajari hubungan matematis antara fitur dan target dengan mencari koefisien regresi yang optimal untuk meminimalkan kesalahan. Sebaliknya, implementasi SVR memerlukan pendekatan yang lebih kompleks karena kinerjanya sangat bergantung pada pemilihan *hyperparameter*. Oleh karena itu, optimasi dilakukan menggunakan GridSearchCV dari Scikit-learn. Sebuah *dictionary* param_grid didefinisikan untuk mencakup ruang pencarian kombinasi *hyperparameter* C, gamma, dan kernel 'rbf'. Objek *grid search* kemudian dikonfigurasi untuk menguji setiap kombinasi ini melalui validasi silang 3-fold (*3-fold cross-validation*) pada data latih. Setelah proses .fit() pada objek *grid search* selesai, model SVR dengan performa terbaik dan konfigurasi *hyperparameter* optimal diekstrak menggunakan atribut .best_estimator_ untuk digunakan pada tahap prediksi selanjutnya.

Setelah model Regresi Linear dan SVR terbaik berhasil dilatih, kedua model tersebut digunakan untuk membuat prediksi pada data uji. Fungsi .predict(X_test) dipanggil pada masing-masing model untuk menghasilkan serangkaian nilai prediksi berdasarkan data fitur dari set data uji yang belum pernah dilihat oleh model. Nilai-nilai prediksi ini kemudian disimpan dalam variabel terpisah (y_pred_lr dan y_pred_svr) untuk dievaluasi pada tahap selanjutnya.

Kinerja prediksi dari kedua model dievaluasi secara kuantitatif menggunakan tiga metrik utama: Koefisien Determinasi (R^2), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE). Perhitungan metrik ini dilakukan dengan fungsi dari pustaka Scikit-learn seperti r2_score dan mean_squared_error, serta fungsi kustom untuk MAPE yang menangani potensi pembagian dengan nol.

Tahap terakhir adalah visualisasi hasil menggunakan pustaka Matplotlib (Hunter, 2007). Proses ini dimulai dengan membuat kanvas gambar menggunakan plt.figure(). Kemudian, tiga plot digambar di atasnya: data harga minyak aktual (y_test) dengan penanda 'o' berwarna hitam, prediksi Regresi Linear dengan gaya garis putus-putus berwarna biru, dan prediksi SVR dengan gaya garis titik-titik berwarna merah. Untuk memastikan grafik informatif dan mudah dibaca, judul dinamis yang mencakup rentang waktu, label untuk sumbu X (Tanggal) dan Y (Harga Minyak Brent (USD)), serta legenda ditambahkan pada setiap plot.

4.4 Evaluasi Kinerja Model

Setelah model dilatih, kinerjanya diuji secara eksklusif pada data uji. Hasil evaluasi kuantitatif dari kedua model pada empat skenario rentang waktu yang berbeda disajikan pada Tabel 3. Temuan utama menunjukkan Perbandingan metrik pola konsisten model Regresi Linear secara definitif menghasilkan kinerja yang lebih superior (tidak seburuk) dibandingkan model SVR di semua skenario. Keunggulan ini terlihat pada semua metrik, di mana Regresi Linear selalu mencatatkan nilai yang lebih baik. Satu-satunya hasil R^2 positif dicapai oleh Regresi Linear pada skenario 7 tahun (0.2442).

Tabel 3. Hasil Evaluasi Kinerja Model Prediksi pada Data Uji

Rentang waktu	Model	R-squared (R^2)	RMSE	MAPE
3 Tahun	Regresi Linear	-2.3425	7.8608	9.80%
	SVR	-4.3907	9.9829	12.77%
5 Tahun	Regresi Linear	-1.2535	5.6817	6.39%
	SVR	-4.3787	8.7779	11.47%
7 Tahun	Regresi Linear	0.2442	5.3503	5.38%
	SVR	-0.5638	7.6961	8.76%
10 Tahun	Regresi Linear	-0.2951	7.7034	8.53%
	SVR	-2.3657	12.4184	12.50%

4.5 Analisis Perbandingan Metrik

Analisis perbandingan metrik secara mendalam menunjukkan bahwa meskipun kedua model secara umum gagal, model Regresi Linear secara konsisten dan definitif menunjukkan kinerja yang lebih baik dibandingkan SVR di semua skenario pengujian. Keunggulan ini terlihat pada metrik R-squared (R^2), di mana SVR selalu menghasilkan nilai yang sangat negatif, sementara Regresi Linear memiliki nilai yang lebih baik dan bahkan menjadi satu-satunya model yang mencapai R^2 positif pada skenario 7 tahun. Pola dominasi ini juga terkonfirmasi pada metrik kesalahan; nilai RMSE dan MAPE dari Regresi Linear secara seragam selalu lebih rendah daripada SVR di setiap rentang waktu yang diuji. Secara keseluruhan, perbandingan ini membuktikan bahwa dalam kerangka penelitian ini, penambahan kompleksitas dari model linear ke model non-linear seperti SVR tidak memberikan keuntungan dan justru secara konsisten memperburuk kinerja prediksi.

4.5 Analisis Kinerja Model Regresi Linear

Model Regresi Linear bekerja dengan mengasumsikan adanya hubungan linear antara variabel independen dan dependen, dengan tujuan menemukan model garis yang paling baik merepresentasikan data dengan meminimalkan jumlah kuadrat kesalahan (Hastie et al., 2009). Dalam penelitian ini, kinerja model Regresi Linear menunjukkan pola yang tidak konsisten. Pada tiga dari empat skenario pengujian (3, 5, dan 10 tahun), model ini menghasilkan nilai R^2 negatif, yang menandakan bahwa hubungan linear yang ditemukan pada data latih tidak dapat digeneralisasi dengan baik pada data uji. Satu-satunya hasil positif yang tercatat adalah pada skenario 7 tahun, di mana model ini berhasil mencapai R^2 sebesar 0.2442 dan MAPE sebesar 5.38%, yang merupakan nilai kesalahan persentase terendah di seluruh pengujian. Kinerja yang menonjol pada periode spesifik ini kemungkinan mengindikasikan bahwa periode tersebut secara kebetulan memiliki tren jangka panjang yang lebih jelas dan stabil, sehingga cocok dengan asumsi linearitas model. Meskipun demikian, karena keberhasilan ini tidak dapat direplikasi secara konsisten, model Regresi Linear tidak cukup andal untuk aplikasi praktis dalam kerangka penelitian ini.

4.6 Analisis Kinerja Model Support Vector Regression (SVR)

Support Vector Regression (SVR) adalah model non-parametrik yang secara teoretis lebih canggih, menggunakan *kernel trick* untuk memetakan data ke ruang berdimensi lebih tinggi guna menemukan hubungan non-linear yang kompleks (Drucker et al., 1997). Meskipun secara teoretis unggul, hasil implementasi SVR dalam penelitian ini dapat disimpulkan sebagai sebuah kegagalan total dan konsisten di semua skenario. Kinerjanya ditandai dengan nilai R^2 yang selalu negatif di setiap pengujian, seperti -4.3907 pada skenario 3 tahun, yang mengartikan kinerjanya jauh lebih buruk daripada model *baseline*. Penyebab paling mungkin dari kinerja yang sangat buruk ini adalah *overfitting* yang parah. Meskipun proses GridSearchCV telah diterapkan untuk mencari *hyperparameter* optimal (Pedregosa et al., 2011) , fleksibilitas tinggi dari kernel RBF kemungkinan besar membuat model "menghafal" *noise* atau pola acak yang ada pada data latih. Ketika dihadapkan pada data uji, pola yang telah dihafal tersebut menjadi tidak relevan dan menghasilkan prediksi yang sangat menyimpang. Kegagalan SVR ini menjadi studi kasus penting yang menunjukkan bahwa penambahan kompleksitas model tanpa didukung oleh sinyal prediktif yang kuat dari fitur-fitur yang ada dapat menjadi sangat merugikan.

4.7 Analisis Visual Hasil Prediksi

Analisis visual dilakukan dengan memplotkan data aktual terhadap hasil prediksi dari kedua model pada data uji untuk memberikan pemahaman intuitif tentang perilaku masing-masing model.

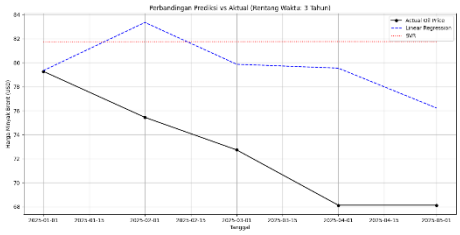

Gambar 5. Grafik 3 Tahun

Pada Gambar 5 menyajikan visualisasi untuk skenario 3 tahun dan secara jelas menunjukkan kegagalan kedua model. Garis Harga Aktual (hitam) menunjukkan fluktuasi yang dinamis, namun kedua garis prediksi (Regresi Linear biru dan SVR merah) sama sekali tidak mampu menangkap dinamika ini dan cenderung datar. Divergensi yang masif antara garis prediksi dan garis aktual ini adalah representasi visual dari nilai R^2 yang sangat negatif, yang menegaskan bahwa model tidak mempelajari pola yang berguna dari data latih yang singkat.

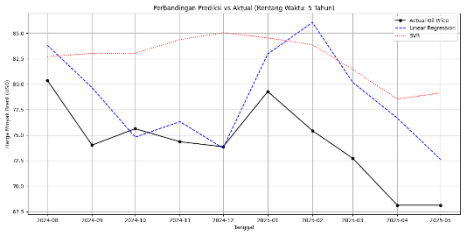

Gambar 6. Grafik 5 Tahun

Pada Gambar 6 menunjukkan perbandingan untuk rentang data 5 tahun, kegagalan generalisasi model kembali terlihat jelas. Meskipun rentang data historis lebih panjang, baik Regresi Linear maupun SVR tidak menunjukkan perbaikan berarti. Garis prediksi Regresi Linear (biru) dan SVR (merah) kembali menunjukkan kecenderungan untuk menghasilkan prediksi yang relatif datar dan gagal total untuk mengikuti tren naik-turun yang tajam dari harga aktual, yang mendukung nilai R^2 yang negatif.

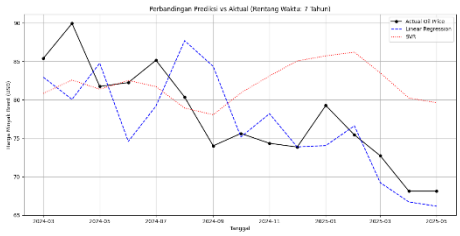

Gambar 7. Grafik 7 Tahun

Pada Gambar 7 untuk skenario 7 tahun menyajikan hasil yang paling menarik. Sesuai dengan hasil R^2 positif, garis prediksi Regresi Linear (biru) secara visual menunjukkan sedikit keberhasilan. Garis biru tersebut, meskipun tidak sempurna, berhasil menangkap arah tren umum dari data aktual yang cenderung menurun secara perlahan selama periode uji. Sebaliknya, garis prediksi SVR (merah) sekali lagi menunjukkan kegagalan, menghasilkan prediksi yang hampir datar dan tidak terpengaruh oleh pola data aktual. Visualisasi ini memperkuat interpretasi bahwa pada jendela waktu 7 tahun ini, terdapat sinyal tren linear yang cukup kuat untuk dapat ditangkap sebagian oleh model Regresi Linear.

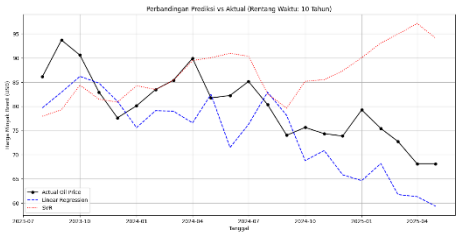

Gambar 8. Grafik 10 Tahun

Pada skenario dengan data historis terpanjang, Gambar 8 menunjukkan bahwa kedua model kembali gagal dalam tugas prediksi. Meskipun diharapkan data yang lebih banyak dapat meningkatkan kinerja, baik Regresi Linear (biru) maupun SVR (merah) menghasilkan garis prediksi yang tidak akurat dan tidak dapat diandalkan. Prediksi yang dihasilkan tidak mampu mengikuti volatilitas harga aktual dan menunjukkan kesalahan yang signifikan di sepanjang periode uji. Kegagalan ini menegaskan kesimpulan bahwa fitur-fitur yang digunakan secara fundamental tidak memiliki daya prediksi yang cukup kuat, bahkan dengan data historis yang melimpah sekalipun.

4.8 Interpretasi dan Implikasi Hasil

Interpretasi utama dari hasil evaluasi adalah bahwa pendekatan pemodelan dan rangkaian fitur yang dipilih terbukti tidak cukup kuat untuk membangun model prediksi yang andal. Fakta bahwa model Regresi Linear yang lebih sederhana secara konsisten lebih baik daripada SVR yang kompleks mengindikasikan bahwa penambahan kompleksitas justru memperburuk kinerja. Implikasi utama bagi PT. XYZ adalah model-model ini tidak boleh digunakan untuk pengambilan keputusan bisnis yang konkret. Namun, penelitian ini memberikan nilai diagnostik penting: pendekatan pemodelan yang hanya mengandalkan data pasar yang mudah diakses tidaklah cukup, yang memberikan justifikasi kuat untuk berinvestasi dalam

pengayaan fitur dengan data fundamental yang lebih relevan.

5. KESIMPULAN

Penelitian ini menyimpulkan bahwa model prediksi harga minyak yang dibangun menggunakan Regresi Linear dan SVR gagal menghasilkan prediksi yang akurat dan andal, yang dibuktikan oleh nilai R^2 yang mayoritas negatif. Dalam perbandingan langsung, model Regresi Linear yang lebih sederhana secara konsisten menunjukkan kinerja yang lebih baik dibandingkan SVR. Kegagalan ini menyiratkan bahwa masalah utama tidak terletak pada algoritma, melainkan pada variabel prediktor yang tidak memiliki daya prediksi yang cukup kuat untuk menangkap dinamika pasar yang kompleks. Berdasarkan temuan ini, disarankan agar penelitian selanjutnya berfokus pada pengayaan fitur dengan data fundamental yang relevan dengan industri energi, seperti data produksi OPEC dan tingkat inventaris global. Selain itu, direkomendasikan untuk mengimplementasikan model yang secara inheren dirancang untuk data deret waktu, seperti ARIMA atau LSTM (Hochreiter & Schmidhuber, 1997) , serta menggunakan teknik validasi yang lebih *robust* seperti *Time-Series Cross-Validation* untuk mendapatkan estimasi kinerja yang lebih andal (Hyndman & Athanasopoulos, 2018).

6. DAFTAR PUSTAKA

Arifin, Z. 2018. Analisis Faktor-Faktor yang Mempengaruhi Harga Minyak Dunia. *Jurnal Ekonomi dan Kebijakan Energi*, 10(2), 45-56.

Chai, T. & Draxler, R. R. 2014. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7(3), 1247–1250.

Drucker, H., Burges, C. J. C., Kaufman, L., Smola, A., & Vapnik, V. (1997). Support Vector Regression Machines. In *Advances in Neural Information Processing Systems* (pp. 155–161).

EIA. 2024. *Petroleum & Other Liquids – Crude Oil Prices*. U.S. Energy Information Administration. Diakses dari https://www.eia.gov

Frost, J. 2020. *Regression analysis: An intuitive guide for using and interpreting linear models*. Statistics By Jim Publishing.

Han, J., Pei, J., & Kamber, M. 2011. *Data Mining: Concepts and Techniques* (3rd ed.). Elsevier.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, *9*(8), 1735-1780.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90-95.

Hussein, M., & Azhar, S. 2021. Machine Learning for Oil Price Prediction: A Comparative Study. *Energy Data hussScience Journal*, 8(2), 112-129.

Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice* (2nd ed.). OTexts.

Investing.com. (2025). *EUR IDR historical data*. Diakses dari https://www.investing.com/currencies/eur-idr-historical-data

Investing.com. (2025). *Gold Spot Prices historical data*. Diakses dari https://www.investing.com/commodities/gold-historical-data

Investing.com. (2025). *USD IDR historical data*. Diakses dari https://www.investing.com/currencies/usd-idr-historical-data

James, G., Witten, D., Hastie, T., & Tibshirani, R. 2013. *An Introduction to Statistical Learning: With Applications in R*. Springer.

Keerthan, R., et al. 2019. Comparison of Supervised Learning Models for Crude Oil Price Prediction. *International Journal of Artificial Intelligence Applications*, 14(3), 120-135.

Kim, H., et al. 2020. Volatility Forecasting in Crude Oil Prices using Machine Learning Approaches. *Journal of Computational Economics*, 27(4), 98-115.

Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. 2005. *Applied Linear Statistical Models* (5th ed.). McGraw-Hill/Irwin.

Makridakis, S., Wheelwright, S. C., &

Hyndman, R. J. 1998. *Forecasting: Methods and Applications* (3rd ed.). Wiley.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Qirani, D., & Sukarsih, R. 2024. Big Data and Machine Learning for Energy Market Prediction. *Journal of Renewable Energy Economics*, 22(1), 45-60.

Smola, A. J., & Schölkopf, B. 2004. A tutorial on support vector regression. *Statistics and Computing*, 14(3), 199–222.

Van Rossum, G., & Drake, F. L. 2006. *The Python language reference manual*. Network Theory Ltd.

Wooldridge, J. M. 2013. *Introductory Econometrics: A Modern Approach* (5th ed.). South-Western Cengage Learning.